Solución del parcial de Teoría de Aprendizaje de Máquina

Periodo 2026-2

Cristian David Dorado Gomez, Juan Diego Restrepo Hernandez

Sección 1. Regresión en espacios de características

Regresión en espacios de características: mínimos cuadrados, máxima verosimilitud y máximo a posteriori.

Sea un conjunto de datos i.i.d.

$$\{(x_n, t_n)\}_{n=1}^{N}, \qquad x_n \in \mathbb{R}^P, \quad t_n \in \mathbb{R},$$

y considere un mapeo explícito $\phi : \mathbb{R}^P \to \mathbb{R}^Q$ y el modelo de regresión

$$t_n = \phi(x_n)^T w + \eta_n, \qquad w \in \mathbb{R}^Q,$$

donde, cuando corresponda, se asumirá $\eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2)$. Sea $\Phi \in \mathbb{R}^{N \times Q}$ la matriz cuyas filas son $\phi(x_n)^T$, y $t \in \mathbb{R}^N$ el vector de respuestas.

Preparación: notación matricial

Cada observación satisface $t_n = \phi(x_n)^T w + \eta_n$. Al apilar las N ecuaciones,

$$\underbrace{\begin{bmatrix} t_1 \\ \vdots \\ t_N \end{bmatrix}}_{t \in \mathbb{R}^N} = \underbrace{\begin{bmatrix} \phi(x_1)^T \\ \vdots \\ \phi(x_N)^T \end{bmatrix}}_{\Phi \in \mathbb{R}^{N \times Q}} \underbrace{w}_{\mathbb{R}^Q} + \underbrace{\begin{bmatrix} \eta_1 \\ \vdots \\ \eta_N \end{bmatrix}}_{\eta \in \mathbb{R}^N}.$$

Por lo tanto, $\boxed{t = \Phi w + \eta}$ y la predicción del modelo es $\hat{t} = \Phi w$.

1.1. Mínimos cuadrados

Enunciado. Plantee la función objetivo y deduzca, paso a paso, el estimador por mínimos cuadrados, incluyendo las condiciones necesarias para la existencia y unicidad de la solución.

Solución paso a paso

Paso 1. Función objetivo. El residuo de la observación n es $e_n = t_n - \phi(x_n)^T w$. La suma de residuos al cuadrado es

$$J(w) = \sum_{n=1}^{N} \left(t_n - \phi(x_n)^T w\right)^2 = \|t - \Phi w\|_2^2.$$

Así, $\hat{w}_{\text{LS}} \in \arg\min_{w \in \mathbb{R}^Q} J(w)$.

Paso 2. Expansión algebraica. Usamos $\|a\|_2^2 = a^T a$:

$$\begin{aligned} J(w) &= (t - \Phi w)^T (t - \Phi w) \\ &= t^T t - t^T \Phi w - w^T \Phi^T t + w^T \Phi^T \Phi w \\ &= t^T t - 2 w^T \Phi^T t + w^T \Phi^T \Phi w, \end{aligned}$$

porque $t^T \Phi w$ es escalar e igual a su transpuesta $w^T \Phi^T t$.

Paso 3. Gradiente. Como $\Phi^T \Phi$ es simétrica,

$$\nabla_w J(w) = -2\Phi^T t + 2\Phi^T \Phi w.$$

Paso 4. Ecuaciones normales. Igualando el gradiente a cero,

$$-2\Phi^T t + 2\Phi^T \Phi w = 0 \iff \boxed{\Phi^T \Phi w = \Phi^T t}.$$

Paso 5. Solución cerrada si hay rango completo. Si $\operatorname{rank}(\Phi) = Q$, entonces $\Phi^T \Phi$ es invertible y

$$\boxed{\hat{w}_{\mathrm{LS}} = (\Phi^T \Phi)^{-1} \Phi^T t}.$$

Esta fórmula exige $N \geq Q$ y columnas linealmente independientes, no solo $N \geq Q$.

Paso 6. ¿Por qué estudiamos $v^T H v$? La Hessiana de la función objetivo es

$$H = \nabla_w^2 J(w) = 2\Phi^T \Phi \in \mathbb{R}^{Q \times Q}.$$

Una matriz simétrica H es semidefinida positiva exactamente cuando $v^T H v \geq 0$ para *todo* $v \in \mathbb{R}^Q$. Se introduce v como dirección de prueba arbitraria: no es una observación ni un parámetro adicional. La forma cuadrática produce un escalar, pues las dimensiones son $(1 \times Q)(Q \times Q)(Q \times 1) = 1 \times 1$.

Para cualquier $v \in \mathbb{R}^Q$,

$$\begin{aligned} v^T H v &= 2 v^T \Phi^T \Phi v \\ &= 2(\Phi v)^T (\Phi v) && \text{ya que } (\Phi v)^T = v^T \Phi^T \\ &= 2\|\Phi v\|_2^2 \geq 0. \end{aligned}$$

Así $H \succeq 0$ y J es convexa; todo punto que satisface las ecuaciones normales es un mínimo global.

Paso 7. Existencia y unicidad. Un minimizador existe siempre: geométricamente, Φw puede elegirse como la proyección ortogonal de t sobre el espacio columna de Φ; algebraicamente, $\Phi^\dagger t$ es un minimizador, donde $\Phi^\dagger$ es la pseudoinversa de Moore–Penrose.

El minimizador es *único* si y solo si $\ker \Phi = \{0\}$, equivalente a $\operatorname{rank}(\Phi) = Q$. En efecto, para todo $v \neq 0$, esto implica $\Phi v \neq 0$ y

$$v^T H v = 2\|\Phi v\|_2^2 > 0,$$

de modo que $H \succ 0$ y J es estrictamente convexa. Si $\operatorname{rank}(\Phi) < Q$, hay algún $v \neq 0$ con $\Phi v = 0$ y, para cualquier minimizador $\hat{w}$, $\hat{w} + v$ produce la misma predicción y el mismo error: no hay unicidad. El conjunto de soluciones es

$$\boxed{\hat{w} = \Phi^\dagger t + (I_Q - \Phi^\dagger \Phi) z, \quad z \in \mathbb{R}^Q,}$$

y $\Phi^\dagger t$ es la de norma mínima.

1.2. Mínimos cuadrados regularizados

Enunciado. Formule el problema con penalización cuadrática $\lambda\|w\|_2^2$, con $\lambda > 0$, y derive su solución cerrada. Explique el efecto del parámetro de regularización.

Solución paso a paso

Paso 1. Penalizar el tamaño de los parámetros. Incorporamos el término $\lambda\|w\|_2^2$, $\lambda > 0$:

$$\boxed{J_\lambda(w) = \|t - \Phi w\|_2^2 + \lambda\|w\|_2^2}.$$

Paso 2. Expandir y derivar.

$$\begin{aligned} J_\lambda(w) &= t^T t - 2w^T\Phi^T t + w^T\Phi^T\Phi w + \lambda w^T w, \\ \nabla_w J_\lambda(w) &= -2\Phi^T t + 2\Phi^T\Phi w + 2\lambda w \\ &= 2(\Phi^T\Phi + \lambda I_Q)w - 2\Phi^T t. \end{aligned}$$

Paso 3. Igualar a cero y despejar.

$$(\Phi^T\Phi + \lambda I_Q)w = \Phi^T t \quad \Longrightarrow \quad \boxed{\hat{w}_{\text{Ridge}} = (\Phi^T\Phi + \lambda I_Q)^{-1}\Phi^T t}.$$

Paso 4. Justificar unicidad. Para todo $v \neq 0$,

$$v^T\nabla^2 J_\lambda(w)v = 2\|\Phi v\|_2^2 + 2\lambda\|v\|_2^2 > 0.$$

Por ser $\lambda > 0$, la Hessiana es definida positiva incluso si Φ no tiene rango completo. Por ello, la solución regularizada existe y es única.

Paso 5. Interpretar λ. Un λ pequeño da mayor importancia al ajuste de los datos; un λ grande contrae los coeficientes hacia cero. Para $\lambda \to \infty$, $\hat{w}_{\text{Ridge}} \to 0$. Para $\lambda \to 0^+$, se recupera $\hat{w}_{\text{LS}}$ cuando hay rango completo y $\Phi^\dagger t$ cuando no lo hay. La regularización mejora el condicionamiento, aunque introduce sesgo.

1.3. Máxima verosimilitud

Enunciado. Bajo el supuesto de ruido gaussiano i.i.d., construya la función de verosimilitud y su logaritmo, y obtenga el estimador de w por máxima verosimilitud. Explicite su relación con mínimos cuadrados.

Solución paso a paso

Paso 1. Distribución de una observación. Se supone

$$\eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2), \qquad \sigma_\eta^2 > 0.$$

Al sumar la media determinista $\phi(x_n)^T w$ al ruido gaussiano,

$$\boxed{t_n \mid x_n, w \sim \mathcal{N}(\phi(x_n)^T w, \sigma_\eta^2)}.$$

Su densidad es

$$p(t_n \mid x_n, w) = \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left[-\frac{(t_n - \phi(x_n)^T w)^2}{2\sigma_\eta^2}\right].$$

Paso 2. Verosimilitud conjunta. La independencia condicional permite multiplicar las densidades:

$$\begin{aligned} L(w) = p(t \mid X, w) &= \prod_{n=1}^{N} p(t_n \mid x_n, w) \\ &= (2\pi\sigma_\eta^2)^{-N/2} \exp\left[-\frac{1}{2\sigma_\eta^2}\sum_{n=1}^{N}(t_n - \phi(x_n)^T w)^2\right] \\ &= \boxed{(2\pi\sigma_\eta^2)^{-N/2} \exp\left[-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2}\right]}. \end{aligned}$$

Aquí X denota el conjunto de entradas conocidas; el diseño está contenido en Φ.

Paso 3. Log-verosimilitud. El logaritmo es estrictamente creciente; por tanto, maximizar L equivale a maximizar $\ell = \log L$:

$$\boxed{\ell(w) = -\frac{N}{2}\log(2\pi\sigma_\eta^2) - \frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2}}.$$

El primer término no depende de w. Si σ_η^2 es fija y positiva, maximizar ℓ equivale a minimizar $\|t - \Phi w\|_2^2$.

Paso 4. Derivar la condición de óptimo.

$$\nabla_w \ell(w) = \frac{1}{\sigma_\eta^2}\Phi^T(t - \Phi w) = 0 \iff \Phi^T\Phi w = \Phi^T t.$$

Con rango completo,

$$\boxed{\hat{w}_{\mathrm{ML}} = (\Phi^T\Phi)^{-1}\Phi^T t = \hat{w}_{\mathrm{LS}}}.$$

Sin rango completo, los conjuntos de minimizadores LS y maximizadores ML también coinciden, pero no son unitarios.

1.4. Máximo a posteriori

Enunciado. Suponga además el prior $w \sim \mathcal{N}(0, \sigma_w^2 I_Q)$. A partir de la regla de Bayes, deduzca el problema de optimización MAP y su solución; establezca la relación entre σ_η^2, σ_w^2 y la regularización cuadrática.

Solución paso a paso

Paso 1. ¿Qué se busca? En ML buscamos un w que haga probables las respuestas dadas las entradas. En MAP se considera, además, una distribución previa de los parámetros:

$$\boxed{w \sim \mathcal{N}(0, \sigma_w^2 I_Q)}, \qquad \sigma_w^2 > 0.$$

La densidad previa es

$$\boxed{p(w) = (2\pi\sigma_w^2)^{-Q/2} \exp\left[-\frac{\|w\|_2^2}{2\sigma_w^2}\right]}.$$

Paso 2. Derivar y adaptar la regla de Bayes. La probabilidad condicional satisface, en el caso discreto, $P(A \mid B) = P(A, B)/P(B)$ y $P(B \mid A) = P(A, B)/P(A)$. Al igualar las dos

expresiones de la conjunta resulta $P(A \mid B) = P(B \mid A)P(A)/P(B)$. La identidad análoga para densidades, aplicada a los parámetros w y las respuestas t y condicionando en las entradas conocidas X, es

$$p(w \mid t, X) = \frac{p(t \mid w, X)\, p(w \mid X)}{p(t \mid X)}.$$

Si el prior no depende de las entradas, $p(w \mid X) = p(w)$, por lo que

$$\boxed{p(w \mid t, X) = \frac{p(t \mid X, w)p(w)}{p(t \mid X)}}.$$

Los términos tienen interpretaciones precisas:

- $p(w \mid t, X)$: densidad *posterior* de los parámetros tras observar los datos.
- $p(t \mid X, w)$: *verosimilitud* de los datos para el valor w.
- $p(w)$: *prior* o creencia probabilística anterior a las respuestas.
- $p(t \mid X)$: *evidencia*, que normaliza la posterior y no depende del w optimizado.

Más precisamente, la evidencia se obtiene integrando el parámetro:

$$p(t \mid X) = \int_{\mathbb{R}^Q} p(t \mid X, u)p(u)\, du.$$

Paso 3. Definir el estimador MAP. Se elige el punto de mayor densidad posterior:

$$\hat{w}_{\text{MAP}} = \arg\max_w p(w \mid t, X) = \arg\max_w \frac{p(t \mid X, w)p(w)}{p(t \mid X)}.$$

Como el denominador es positivo e independiente de w,

$$\boxed{\hat{w}_{\text{MAP}} = \arg\max_w p(t \mid X, w)p(w)}.$$

La diferencia con ML es que MAP combina *datos más prior*, mientras que ML usa solo la verosimilitud.

Paso 4. Sustituir las gaussianas. De la sección 1.3 y del prior,

$$p(t \mid X, w)p(w) = (2\pi\sigma_\eta^2)^{-N/2}(2\pi\sigma_w^2)^{-Q/2} \times \exp\left[-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2} - \frac{\|w\|_2^2}{2\sigma_w^2}\right].$$

El logaritmo negativo transforma el máximo en un mínimo y convierte el producto en una suma. Tras descartar constantes independientes de w:

$$\boxed{\hat{w}_{\text{MAP}} = \arg\min_w \left\{\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2} + \frac{\|w\|_2^2}{2\sigma_w^2}\right\}}.$$

Paso 5. Conectar con Ridge. Multiplicamos la función por la constante positiva $2\sigma_\eta^2$, sin cambiar el minimizador:

$$\hat{w}_{\text{MAP}} = \arg\min_w \left\{\|t - \Phi w\|_2^2 + \frac{\sigma_\eta^2}{\sigma_w^2}\|w\|_2^2\right\}.$$

Comparando con $\|t - \Phi w\|_2^2 + \lambda\|w\|_2^2$,

$$\boxed{\lambda = \frac{\sigma_\eta^2}{\sigma_w^2}}.$$

Paso 6. Calcular el estimador. Derivamos la función MAP original:

$$\nabla_w J_{\text{MAP}}(w) = -\frac{1}{\sigma_\eta^2}\Phi^T(t - \Phi w) + \frac{1}{\sigma_w^2}w.$$

Al igualar a cero y multiplicar por σ_η^2,

$$-\Phi^T t + \Phi^T\Phi w + \frac{\sigma_\eta^2}{\sigma_w^2}w = 0,$$
$$\left(\Phi^T\Phi + \frac{\sigma_\eta^2}{\sigma_w^2}I_Q\right)w = \Phi^T t.$$

Por tanto,

$$\boxed{\hat{w}_{\text{MAP}} = \left(\Phi^T\Phi + \frac{\sigma_\eta^2}{\sigma_w^2}I_Q\right)^{-1}\Phi^T t}.$$

Como las dos varianzas son positivas, $\lambda > 0$ y la matriz invertida es definida positiva; el estimador MAP es único.

Paso 7. Interpretación. Aumentar σ_η^2 (ruido) aumenta λ y da relativamente más peso al prior. Aumentar σ_w^2 hace el prior más difuso, reduce λ y disminuye la penalización. El prior centrado en cero induce la contracción de los pesos hacia cero.

Síntesis de la sección 1

$\boxed{\hat{w}_{\text{LS}}}$	$= \boxed{(\Phi^T\Phi)^{-1}\Phi^T t}$	si $\text{rank}(\Phi) = Q$,
$\boxed{\hat{w}_{\text{Ridge}}}$	$= \boxed{(\Phi^T\Phi + \lambda I_Q)^{-1}\Phi^T t}$	si $\lambda > 0$,
$\boxed{\hat{w}_{\text{ML}}}$	$= \boxed{\hat{w}_{\text{LS}}}$	con ruido gaussiano i.i.d.,
$\boxed{\hat{w}_{\text{MAP}}}$	$= \boxed{\hat{w}_{\text{Ridge}}}$	con $\lambda = \sigma_\eta^2/\sigma_w^2$.

Condiciones esenciales: LS/ML siempre tienen al menos una solución, pero solo es única si $\text{rank}(\Phi) = Q$. Ridge/MAP, con $\lambda > 0$, tienen una única solución aunque Φ sea deficiente en rango.

Sección 2. Espacios RKHS, embeddings de media y discrepancia entre distribuciones

Sea $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ un kernel simétrico y definido positivo, y sea $\mathcal{H}_k$ su espacio de Hilbert con núcleo reproductor (RKHS) asociado. Por definición positiva, para $x_1, \ldots, x_N \in \mathcal{X}$ y $c_1, \ldots, c_N \in \mathbb{R}$,

$$\sum_{i=1}^{N} \sum_{j=1}^{N} c_i c_j k(x_i, x_j) \geq 0. \tag{1}$$

Asimismo, $k(x, x') = k(x', x)$. Un ejemplo de kernel es el gaussiano:

$$k(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right). \tag{2}$$

Propiedad reproductora

Para todo $x \in \mathcal{X}$, la función $k(x, \cdot)$ pertenece a $\mathcal{H}_k$ y, para todo $f \in \mathcal{H}_k$, se cumple

$$\boxed{f(x) = \langle f, k(x, \cdot) \rangle_{\mathcal{H}_k}.} \tag{3}$$

En particular, si elegimos $f = k(x', \cdot)$, obtenemos

$$k(x', x) = \langle k(x', \cdot), k(x, \cdot) \rangle_{\mathcal{H}_k} \tag{4}$$

$$= \langle k(x, \cdot), k(x', \cdot) \rangle_{\mathcal{H}_k}. \tag{5}$$

Por la simetría de k:

$$\boxed{\langle k(x, \cdot), k(x', \cdot) \rangle_{\mathcal{H}_k} = k(x, x').} \tag{6}$$

Esta identidad transforma productos internos del RKHS en evaluaciones del kernel y es clave para la MMD.

El símbolo $\cdot$ deja libre el segundo argumento; al fijar x, la expresión $z \mapsto k(x, z)$ es una función de z, no un escalar fijo.

2.1. definición rigurosa del embedding de media

Enunciado. Definir rigurosamente el embedding de media asociado a una variable aleatoria X:

$$\mu_k = \mathbb{E}[k(X, \cdot)]. \tag{7}$$

Paso 1. Variable aleatoria y distribución

Sea $X : \Omega \to \mathcal{X}$ una variable aleatoria de distribución P_X. Se desea representar la distribución P_X mediante un elemento del RKHS.

Paso 2. Mapa de características canónico

Definimos

$$\boxed{\phi : \mathcal{X} \longrightarrow \mathcal{H}_k, \qquad \phi(x) = k(x, \cdot).} \tag{8}$$

Entonces $\phi(X) = k(X, \cdot)$ es una variable aleatoria con valores en $\mathcal{H}_k$ (suponiendo la medibilidad pertinente).

Paso 3. Esperanza en un espacio de Hilbert

Así como una esperanza real se expresa mediante una integral, definimos la esperanza de $\phi(X)$ mediante la integral de Bochner:

$$\boxed{\mu_{P_X} = \mathbb{E}_{X\sim P_X}[\phi(X)] = \mathbb{E}_{X\sim P_X}[k(X,\cdot)] = \int_{\mathcal{X}} k(x,\cdot)\, dP_X(x).} \tag{9}$$

La integral está valorada en $\mathcal{H}_k$; por tanto, su resultado es una función del RKHS.

Paso 4. Condiciones de existencia

Una condición suficiente para que la integral de Bochner exista es que $x \mapsto k(x,\cdot)$ sea fuertemente medible y

$$\mathbb{E}[\, \|k(X,\cdot)\|_{\mathcal{H}_k}\,] < \infty. \tag{10}$$

De la propiedad reproductora,

$$\|k(x,\cdot)\|^2_{\mathcal{H}_k} = \langle k(x,\cdot), k(x,\cdot)\rangle_{\mathcal{H}_k} = k(x,x). \tag{11}$$

En consecuencia, la condición de integrabilidad adopta la forma

$$\boxed{\mathbb{E}\left[\sqrt{k(X,X)}\right] < \infty.} \tag{12}$$

Por ejemplo, si $k(x,x) \le C < \infty$ para todo x, esta condición se satisface automáticamente.

2.2. pertenencia al RKHS e interpretación geométrica

Enunciado. Explicar por qué $\mu_k \in \mathcal{H}_k$ e interpretar geométricamente su significado como representante de la distribución de X.

Paso 1. Los elementos del kernel pertenecen al RKHS

Para cualquier observación $x_i \in \mathcal{X}$, la definición de RKHS garantiza que

$$k(x_i,\cdot) \in \mathcal{H}_k. \tag{13}$$

Paso 2. Por qué podemos formar combinaciones lineales

El RKHS es un espacio vectorial. Si $f, g \in \mathcal{H}_k$ y $a, b \in \mathbb{R}$, entonces $af + bg \in \mathcal{H}_k$. Por inducción, toda combinación lineal finita de funciones de $\mathcal{H}_k$ también está en $\mathcal{H}_k$. En particular,

$$\boxed{\widehat{\mu}_k = \frac{1}{n}\sum_{i=1}^{n} k(x_i,\cdot) \in \mathcal{H}_k.} \tag{14}$$

Esto prueba la pertenencia del *embedding empírico*; aún falta justificar la pertenencia del embedding poblacional.

Paso 3. Por qué el promedio aproxima la esperanza

Si $x_1, \ldots, x_n$ son observaciones independientes e idénticamente distribuidas (i.i.d.) según P_X, definimos variables aleatorias con valores en $\mathcal{H}_k$:

$$Z_i = \phi(x_i) = k(x_i, \cdot). \tag{15}$$

Su media muestral es

$$\overline{Z}_n = \frac{1}{n}\sum_{i=1}^{n} Z_i = \frac{1}{n}\sum_{i=1}^{n} k(x_i, \cdot) = \widehat{\mu}_k. \tag{16}$$

Si $\phi(X)$ es fuertemente medible y $\mathbb{E}[\|\phi(X)\|_{\mathcal{H}_k}] < \infty$, la ley fuerte de los grandes números para variables aleatorias con valores en un espacio de Hilbert implica

$$\boxed{\|\widehat{\mu}_k - \mu_k\|_{\mathcal{H}_k} \xrightarrow[n\to\infty]{\text{c.s.}} 0.} \tag{17}$$

Así, el promedio empírico converge casi seguramente al embedding poblacional en la norma del RKHS.

Paso 4. Pertenencia del embedding poblacional

La esperanza μ_k se define como integral de Bochner de $\phi(X)$; dicha integral se construye mediante límites en norma de integrales de funciones simples. Como $\mathcal{H}_k$ es completo, el límite pertenece a $\mathcal{H}_k$. En las condiciones del numeral 2.1,

$$\boxed{\mu_k = \mathbb{E}[\phi(X)] \in \mathcal{H}_k.} \tag{18}$$

Dos justificaciones diferentes: la estructura vectorial prueba que cada promedio *finito* está en $\mathcal{H}_k$; la integrabilidad y la completitud garantizan que la *esperanza poblacional* también está en $\mathcal{H}_k$. La ley de los grandes números explica la aproximación del segundo por el primero.

Paso 5. Interpretación geométrica

El mapa $x \mapsto \phi(x)$ lleva observaciones del dominio original a funciones del RKHS. La esperanza

$$\mu_k = \mathbb{E}[\phi(X)] \tag{19}$$

es el **centroide o centro de masa** de la distribución de características transformadas. Puede hallarse en un espacio de dimensión infinita y no necesariamente coincide con una característica $\phi(x)$ de una observación particular.

Paso 6. El embedding representa esperanzas

Para todo $f \in \mathcal{H}_k$, por la propiedad reproductora,

$$f(X) = \langle f, k(X, \cdot)\rangle_{\mathcal{H}_k}. \tag{20}$$

Tomamos esperanza y usamos que, con f fijo, $g \mapsto \langle f, g\rangle_{\mathcal{H}_k}$ es un funcional lineal continuo:

$$\mathbb{E}[f(X)] = \mathbb{E}\left[\langle f, k(X, \cdot)\rangle_{\mathcal{H}_k}\right] \tag{21}$$

$$= \langle f, \mathbb{E}[k(X,\cdot)] \rangle_{\mathcal{H}_k} \tag{22}$$
$$= \langle f, \mu_k \rangle_{\mathcal{H}_k} . \tag{23}$$

Por tanto,

$$\boxed{\mathbb{E}[f(X)] = \langle f, \mu_k \rangle_{\mathcal{H}_k} , \qquad \forall f \in \mathcal{H}_k.} \tag{24}$$

El embedding almacena las esperanzas de todas las funciones del RKHS. Que represente *unívocamente* una distribución requiere que el kernel sea *característico*.

Ejemplo: kernel lineal

Consideremos $\mathcal{X} = \mathbb{R}$ y $k(x,z) = xz$. Su RKHS se identifica con las funciones $f_a(z) = az$ y $\phi(x)(z) = xz$. Para las observaciones $x_1 = 2$, $x_2 = 4$ y $x_3 = 6$,

$$\widehat{\mu}_k(z) = \frac{1}{3}[k(2,z) + k(4,z) + k(6,z)] \tag{25}$$
$$= \frac{1}{3}(2z + 4z + 6z) = 4z. \tag{26}$$

Las tres funciones pertenecen al RKHS y su promedio $z \mapsto 4z$ también. En este ejemplo, el embedding empírico incorpora la media aritmética 4 de las observaciones.

2.3. discrepancia máxima de medias (MMD)

Enunciado. Sean $X \sim P_X$ e $Y \sim P_Y$ variables aleatorias independientes en $\mathcal{X}$, con embeddings μ_X y μ_Y. Se define

$$\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k} . \tag{27}$$

Se pide obtener la forma matricial del estimador empírico sesgado a partir de muestras independientes $\{x_i\}_{i=1}^n$ y $\{y_j\}_{j=1}^m$.

Paso 1. Desarrollar la norma cuadrática

La norma inducida por un producto interno satisface $\|a\|^2 = \langle a, a \rangle$. Por tanto,

$$\mathrm{MMD}^2(P_X, P_Y) = \langle \mu_X - \mu_Y, \mu_X - \mu_Y \rangle_{\mathcal{H}_k} \tag{28}$$
$$= \langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} + \langle \mu_Y, \mu_Y \rangle_{\mathcal{H}_k} - 2 \langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k} . \tag{29}$$

Paso 2. Primer producto interno poblacional

Sea X' una copia independiente de X, con la misma distribución P_X. Sustituyendo los embeddings y llevando la esperanza al producto interno,

$$\langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} = \langle \mathbb{E}_X[k(X,\cdot)], \mathbb{E}_{X'}[k(X',\cdot)] \rangle_{\mathcal{H}_k} \tag{30}$$
$$= \mathbb{E}_{X,X'} \left[\langle k(X,\cdot), k(X',\cdot) \rangle_{\mathcal{H}_k} \right] \tag{31}$$
$$= \mathbb{E}_{X,X'}[k(X,X')]. \tag{32}$$

La última igualdad se debe a la propiedad reproductora (6).

Paso 3. Segundo producto interno poblacional

Análogamente, con Y' una copia independiente de Y,

$$\boxed{\langle \mu_Y, \mu_Y \rangle_{\mathcal{H}_k} = \mathbb{E}_{Y,Y'}[k(Y, Y')].} \tag{33}$$

Paso 4. Producto interno cruzado

Usando la independencia entre X e Y,

$$\begin{aligned} \langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k} &= \langle \mathbb{E}_X[k(X,\cdot)], \mathbb{E}_Y[k(Y,\cdot)] \rangle_{\mathcal{H}_k} && (34)\\ &= \mathbb{E}_{X,Y}\left[\langle k(X,\cdot), k(Y,\cdot) \rangle_{\mathcal{H}_k} \right] && (35)\\ &= \mathbb{E}_{X,Y}[k(X,Y)]. && (36) \end{aligned}$$

Paso 5. Expresión poblacional

Sustituimos (32), (33) y (36) en (29):

$$\boxed{\begin{aligned} \mathrm{MMD}^2(P_X, P_Y) = \mathbb{E}_{X,X'}[k(X,X')] \\ + \mathbb{E}_{Y,Y'}[k(Y,Y')] \\ - 2\mathbb{E}_{X,Y}[k(X,Y)]. \end{aligned}} \tag{37}$$

Esta expresión utiliza esperanzas respecto a distribuciones, no sumas muestrales.

Paso 6. Construcción de los embeddings empíricos

Sean $x_1, \ldots, x_n \overset{\text{i.i.d.}}{\sim} P_X$ y $y_1, \ldots, y_m \overset{\text{i.i.d.}}{\sim} P_Y$, con ambas muestras independientes. Definimos

$$\widehat{\mu}_X = \frac{1}{n}\sum_{i=1}^{n} k(x_i, \cdot), \qquad \widehat{\mu}_Y = \frac{1}{m}\sum_{j=1}^{m} k(y_j, \cdot). \tag{38}$$

El estimador empírico sesgado de la MMD cuadrática es

$$\widehat{\mathrm{MMD}}_b^2 = \|\widehat{\mu}_X - \widehat{\mu}_Y\|_{\mathcal{H}_k}^2 . \tag{39}$$

Al desarrollar el cuadrado,

$$\widehat{\mathrm{MMD}}_b^2 = \langle \widehat{\mu}_X, \widehat{\mu}_X \rangle_{\mathcal{H}_k} + \langle \widehat{\mu}_Y, \widehat{\mu}_Y \rangle_{\mathcal{H}_k} - 2\langle \widehat{\mu}_X, \widehat{\mu}_Y \rangle_{\mathcal{H}_k} . \tag{40}$$

Paso 7. Primer término empírico

Por bilinealidad y la propiedad reproductora,

$$\begin{aligned} \langle \widehat{\mu}_X, \widehat{\mu}_X \rangle_{\mathcal{H}_k} &= \left\langle \frac{1}{n}\sum_{i=1}^{n} k(x_i,\cdot), \frac{1}{n}\sum_{j=1}^{n} k(x_j,\cdot) \right\rangle_{\mathcal{H}_k} && (41)\\ &= \frac{1}{n^2}\sum_{i=1}^{n}\sum_{j=1}^{n} \langle k(x_i,\cdot), k(x_j,\cdot) \rangle_{\mathcal{H}_k} && (42) \end{aligned}$$

$$= \frac{1}{n^2} \sum_{i=1}^{n} \sum_{j=1}^{n} k(x_i, x_j). \tag{43}$$

Se incluyen todos los pares, incluso los diagonales $i = j$.

Paso 8. Segundo término empírico

De manera análoga,

$$\langle \widehat{\mu}_Y, \widehat{\mu}_Y \rangle_{\mathcal{H}_k} = \frac{1}{m^2} \sum_{i=1}^{m} \sum_{j=1}^{m} k(y_i, y_j). \tag{44}$$

Paso 9. Término cruzado empírico

Por bilinealidad,

$$\langle \widehat{\mu}_X, \widehat{\mu}_Y \rangle_{\mathcal{H}_k} = \left\langle \frac{1}{n} \sum_{i=1}^{n} k(x_i, \cdot), \frac{1}{m} \sum_{j=1}^{m} k(y_j, \cdot) \right\rangle_{\mathcal{H}_k} \tag{45}$$

$$= \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} \langle k(x_i, \cdot), k(y_j, \cdot) \rangle_{\mathcal{H}_k} \tag{46}$$

$$= \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} k(x_i, y_j). \tag{47}$$

El factor $1/(nm)$ surge porque se forman nm parejas entre ambas muestras.

Paso 10. Forma empírica mediante sumatorias

Al sustituir (43)–(47) en (40), queda

$$\widehat{\mathrm{MMD}}_b^2 = \frac{1}{n^2} \sum_{i=1}^{n} \sum_{j=1}^{n} k(x_i, x_j) + \frac{1}{m^2} \sum_{i=1}^{m} \sum_{j=1}^{m} k(y_i, y_j) - \frac{2}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} k(x_i, y_j). \tag{48}$$

Paso 11. Definir las matrices de Gram

Definimos

$$K_{XX} = [k(x_i, x_j)]_{i,j=1}^{n} \in \mathbb{R}^{n \times n}, \tag{49}$$

$$K_{YY} = [k(y_i, y_j)]_{i,j=1}^{m} \in \mathbb{R}^{m \times m}, \tag{50}$$

$$K_{XY} = [k(x_i, y_j)]_{\substack{i=1,\dots,n \\ j=1,\dots,m}} \in \mathbb{R}^{n \times m}. \tag{51}$$

Por ejemplo,

$$K_{XY} = \begin{bmatrix} k(x_1, y_1) & \cdots & k(x_1, y_m) \\ \vdots & \ddots & \vdots \\ k(x_n, y_1) & \cdots & k(x_n, y_m) \end{bmatrix}. \tag{52}$$

Sean $\mathbf{1}_n = (1, \ldots, 1)^T \in \mathbb{R}^{n\times 1}$ y $\mathbf{1}_m \in \mathbb{R}^{m\times 1}$.

Paso 12. Convertir las sumatorias a productos matriciales

La multiplicación por un vector de unos suma filas y columnas. Así,

$$\mathbf{1}_n^T K_{XX} \mathbf{1}_n = \sum_{i=1}^{n}\sum_{j=1}^{n} k(x_i, x_j), \tag{53}$$

$$\mathbf{1}_m^T K_{YY} \mathbf{1}_m = \sum_{i=1}^{m}\sum_{j=1}^{m} k(y_i, y_j), \tag{54}$$

$$\mathbf{1}_n^T K_{XY} \mathbf{1}_m = \sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j). \tag{55}$$

Por ejemplo,

$$K_{XX}\mathbf{1}_n = \begin{bmatrix} \sum_{j=1}^{n} k(x_1, x_j) \\ \vdots \\ \sum_{j=1}^{n} k(x_n, x_j) \end{bmatrix}, \tag{56}$$

y multiplicar por $\mathbf{1}_n^T$ desde la izquierda suma sus componentes.

Paso 13. Expresión matricial solicitada

Sustituyendo en (48):

$$\boxed{\begin{aligned} \widehat{\mathrm{MMD}}_b^2 = {} & \frac{1}{n^2}\mathbf{1}_n^T K_{XX}\mathbf{1}_n \\ & + \frac{1}{m^2}\mathbf{1}_m^T K_{YY}\mathbf{1}_m \\ & - \frac{2}{nm}\mathbf{1}_n^T K_{XY}\mathbf{1}_m. \end{aligned}} \tag{57}$$

Esta es la identidad que solicita demostrar el parcial.

Paso 14. Justificar las dimensiones

Cada producto es escalar, pues

$$\underbrace{\mathbf{1}_n^T}_{1\times n}\underbrace{K_{XX}}_{n\times n}\underbrace{\mathbf{1}_n}_{n\times 1} \in \mathbb{R}^{1\times 1}, \tag{58}$$

$$\underbrace{\mathbf{1}_m^T}_{1\times m}\underbrace{K_{YY}}_{m\times m}\underbrace{\mathbf{1}_m}_{m\times 1} \in \mathbb{R}^{1\times 1}, \tag{59}$$

$$\underbrace{\mathbf{1}_n^T}_{1\times n}\underbrace{K_{XY}}_{n\times m}\underbrace{\mathbf{1}_m}_{m\times 1} \in \mathbb{R}^{1\times 1}. \tag{60}$$

Esto hace válida la suma algebraica de los tres términos en (57).

Paso 15. Por qué es un estimador sesgado

La forma empírica incorpora términos diagonales $k(x_i, x_i)$ y $k(y_j, y_j)$, a diferencia de las esperanzas poblacionales basadas en copias independientes. De hecho,

$$\mathbb{E}\left[\frac{1}{n^2}\sum_{i,j=1}^{n} k(x_i, x_j)\right] = \frac{n(n-1)}{n^2}\mathbb{E}[k(X, X')] \tag{61}$$

$$+ \frac{n}{n^2}\mathbb{E}[k(X, X)], \tag{62}$$

puesto que hay $n(n-1)$ parejas con índices distintos y n términos diagonales. Por tanto, el sesgo total es

$$\begin{aligned}&\mathbb{E}[\widehat{\mathrm{MMD}}_b^2] - \mathrm{MMD}^2(P_X, P_Y)\\ &= \frac{1}{n}\left(\mathbb{E}[k(X, X)] - \mathbb{E}[k(X, X')]\right)\\ &\quad + \frac{1}{m}\left(\mathbb{E}[k(Y, Y)] - \mathbb{E}[k(Y, Y')]\right).\end{aligned} \tag{63}$$

Ambas diferencias son no negativas; por ejemplo,

$$\mathbb{E}[k(X, X)] - \mathbb{E}[k(X, X')] = \mathbb{E}\Big[\|\phi(X) - \mu_X\|_{\mathcal{H}_k}^2\Big] \geq 0, \tag{64}$$

si los momentos necesarios son finitos. Así, el estimador sesgado tiene sesgo no negativo y normalmente positivo, aunque puede anularse en casos particulares. Asimismo, por ser una norma cuadrática,

$$\widehat{\mathrm{MMD}}_b^2 = \|\widehat{\mu}_X - \widehat{\mu}_Y\|_{\mathcal{H}_k}^2 \geq 0. \tag{65}$$

Paso 16. Comparación con el estimador insesgado

Para $n, m \geq 2$, el estimador insesgado de la MMD cuadrática excluye las diagonales de los dos términos internos:

$$\begin{aligned}\widehat{\mathrm{MMD}}_u^2 = &\frac{1}{n(n-1)}\sum_{i\neq j} k(x_i, x_j)\\ &+ \frac{1}{m(m-1)}\sum_{i\neq j} k(y_i, y_j)\\ &- \frac{2}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j).\end{aligned} \tag{66}$$

Siempre que las esperanzas existan,

$$\mathbb{E}[\widehat{\mathrm{MMD}}_u^2] = \mathrm{MMD}^2(P_X, P_Y). \tag{67}$$

Sin embargo, $\widehat{\mathrm{MMD}}_u^2$ puede tomar valores negativos para una muestra finita, a diferencia de $\widehat{\mathrm{MMD}}_b^2$.

Resumen de la sección 2

La demostración del numeral 2.3 sigue la cadena

norma cuadrática $\longrightarrow$ productos internos $\longrightarrow$ kernel $\longrightarrow$ sumatorias $\longrightarrow$ matrices.

Conclusión. El kernel permite representar distribuciones mediante elementos de un RKHS, y la MMD mide la separación entre sus embeddings. Si $P_X = P_Y$, entonces $\mathrm{MMD}(P_X, P_Y) = 0$. La implicación recíproca requiere un kernel característico.

Sección 3. Índice de correlación de Pearson: espacio original y RKHS

3.1. Coeficiente de Pearson en el espacio original

Enunciado. Sean X y Y variables aleatorias escalares, con varianzas positivas, y sean $\mathbf{x}, \mathbf{y} \in \mathbb{R}^{N\times 1}$ vectores de N observaciones emparejadas. Partiendo de

$$\rho_{XY} = \frac{\mathbb{E}[(X-\mu_X)(Y-\mu_Y)]}{\sqrt{\mathbb{E}[(X-\mu_X)^2]\,\mathbb{E}[(Y-\mu_Y)^2]}}, \tag{68}$$

demostrar que su estimador muestral admite la forma

$$\boxed{\widehat{\rho}_{XY} = \frac{\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y}}{\sqrt{(\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x})(\mathbf{y}^\mathsf{T}\mathbf{H}\mathbf{y})}}, \qquad \mathbf{H} = \mathbf{I}_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\mathsf{T}.} \tag{69}$$

Justificar las medias, las sumatorias, el centrado y las dimensiones.

Paso 1. Paso de la definición poblacional a su versión muestral

Sean (x_i, y_i), $i = 1, \ldots, N$, observaciones emparejadas. Las medias son

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i, \qquad \bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i. \tag{70}$$

Sustituyendo las esperanzas por promedios muestrales se obtiene

$$\widehat{\rho}_{XY} = \frac{N^{-1}\sum_{i=1}^{N}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\left[N^{-1}\sum_{i=1}^{N}(x_i-\bar{x})^2\right]\left[N^{-1}\sum_{i=1}^{N}(y_i-\bar{y})^2\right]}} \tag{71}$$

$$= \frac{\sum_{i=1}^{N}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{N}(x_i-\bar{x})^2\sum_{i=1}^{N}(y_i-\bar{y})^2}}. \tag{72}$$

El factor $1/N$ se cancela. También se obtendría el mismo cociente usando el factor $1/(N-1)$ en la covarianza y las varianzas muestrales.

Paso 2. Expresión matricial de las medias y del centrado

Definimos

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_N \end{bmatrix}, \qquad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}, \qquad \mathbf{1}_N = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}. \tag{73}$$

Entonces $\mathbf{1}_N^\mathsf{T}\mathbf{x} = \sum_i x_i$ y, por tanto,

$$\bar{x} = \frac{1}{N}\mathbf{1}_N^\mathsf{T}\mathbf{x}, \qquad \bar{y} = \frac{1}{N}\mathbf{1}_N^\mathsf{T}\mathbf{y}. \tag{74}$$

El vector centrado de X es

$$\begin{aligned}
\mathbf{x}_c &= \mathbf{x} - \bar{x}\mathbf{1}_N && (75)\\
&= \mathbf{x} - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\mathsf{T}\mathbf{x} && (76)\\
&= \underbrace{\left(\mathbf{I}_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\mathsf{T}\right)}_{\mathbf{H}}\mathbf{x} = \mathbf{H}\mathbf{x}. && (77)
\end{aligned}$$

De modo análogo, $\mathbf{y}_c = \mathbf{H}\mathbf{y}$.

Paso 3. Propiedades de la matriz de centrado

Por transposición,

$$\mathbf{H}^\mathsf{T} = \left(\mathbf{I}_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\mathsf{T}\right)^\mathsf{T} = \mathbf{H}. \tag{78}$$

Además, como $\mathbf{1}_N^\mathsf{T}\mathbf{1}_N = N$,

$$\begin{aligned}
\mathbf{H}^2 &= \left(\mathbf{I}_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\mathsf{T}\right)^2 && (79)\\
&= \mathbf{I}_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\mathsf{T} + \frac{1}{N^2}\mathbf{1}_N(\mathbf{1}_N^\mathsf{T}\mathbf{1}_N)\mathbf{1}_N^\mathsf{T} && (80)\\
&= \mathbf{I}_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\mathsf{T} = \mathbf{H}. && (81)
\end{aligned}$$

Así, $\mathbf{H}$ es simétrica e idempotente. También $\mathbf{H}\mathbf{1}_N = \mathbf{0}$: el vector centrado tiene media cero. En efecto, $\mathbf{1}_N^\mathsf{T}\mathbf{H}\mathbf{x} = 0$.

Paso 4. Numerador como producto interno

El numerador de (72) es

$$\begin{aligned}
\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y}) &= \mathbf{x}_c^\mathsf{T}\mathbf{y}_c && (82)\\
&= (\mathbf{H}\mathbf{x})^\mathsf{T}(\mathbf{H}\mathbf{y}) && (83)\\
&= \mathbf{x}^\mathsf{T}\mathbf{H}^\mathsf{T}\mathbf{H}\mathbf{y} && (84)\\
&= \boxed{\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y}}, && (85)
\end{aligned}$$

donde se usó $\mathbf{H}^\mathsf{T}\mathbf{H} = \mathbf{H}^2 = \mathbf{H}$.

Paso 5. Denominador como normas cuadráticas

Por el mismo razonamiento,

$$\sum_{i=1}^{N}(x_i - \bar{x})^2 = \mathbf{x}_c^\mathsf{T}\mathbf{x}_c = \mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x}, \tag{86}$$

$$\sum_{i=1}^{N}(y_i-\bar{y})^2=\mathbf{y}_c^{\mathsf{T}}\mathbf{y}_c=\mathbf{y}^{\mathsf{T}}\mathbf{H}\mathbf{y}. \tag{87}$$

Sustituyendo en (72), se llega a (69), como se quería demostrar.

Paso 6. Comprobación de dimensiones

Objeto	Dimensión
$\mathbf{x},\mathbf{y},\mathbf{1}_N$	$N\times 1$
$\mathbf{H},\mathbf{I}_N,\mathbf{1}_N\mathbf{1}_N^{\mathsf{T}}$	$N\times N$
$\mathbf{H}\mathbf{x},\mathbf{H}\mathbf{y}$	$N\times 1$
$\mathbf{x}^{\mathsf{T}}\mathbf{H}\mathbf{y}$	1×1
$\mathbf{x}^{\mathsf{T}}\mathbf{H}\mathbf{x},\mathbf{y}^{\mathsf{T}}\mathbf{H}\mathbf{y}$	1×1

El resultado es un escalar. La hipótesis de varianzas muestrales no nulas garantiza que el denominador sea distinto de cero.

3.2. Correlación matricial en RKHS

Enunciado. Sean $X\in\mathbb{R}^P$ y $Y\in\mathbb{R}^Q$ y sus kernels k_X,k_Y, con matrices de Gram $\mathbf{K}_X,\mathbf{K}_Y\in\mathbb{R}^{N\times N}$. Se desea demostrar

$$\boxed{\rho_{\mathrm{RKHS}}(\mathbf{K}_X,\mathbf{K}_Y)=\frac{\operatorname{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_Y\mathbf{H})}{\sqrt{\operatorname{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_X\mathbf{H})\operatorname{tr}(\mathbf{K}_Y\mathbf{H}\mathbf{K}_Y\mathbf{H})}}.} \tag{88}$$

Además, para kernels lineales con $P=Q=1$, demostrar que $\rho_{\mathrm{RKHS}}=\widehat{\rho}_{XY}^{\,2}$ y explicar la pérdida del signo.

Paso 1. Mapas de características y matrices de Gram

Sean $\phi_X:\mathbb{R}^P\to\mathcal{H}_X$ y $\phi_Y:\mathbb{R}^Q\to\mathcal{H}_Y$ mapas de características tales que

$$k_X(\mathbf{x}_i,\mathbf{x}_j)=\langle\phi_X(\mathbf{x}_i),\phi_X(\mathbf{x}_j)\rangle_{\mathcal{H}_X}, \tag{89}$$
$$k_Y(\mathbf{y}_i,\mathbf{y}_j)=\langle\phi_Y(\mathbf{y}_i),\phi_Y(\mathbf{y}_j)\rangle_{\mathcal{H}_Y}. \tag{90}$$

Las matrices de Gram se definen por

$$(\mathbf{K}_X)_{ij}=k_X(\mathbf{x}_i,\mathbf{x}_j),\qquad(\mathbf{K}_Y)_{ij}=k_Y(\mathbf{y}_i,\mathbf{y}_j). \tag{91}$$

Ambas son reales, simétricas y semidefinidas positivas; sus dimensiones son $N\times N$, independientemente de P y Q.

Paso 2. Centrado de las características y de las matrices de Gram

Definimos la media empírica en $\mathcal{H}_X$ por

$$\bar{\phi}_X=\frac{1}{N}\sum_{r=1}^{N}\phi_X(\mathbf{x}_r),\qquad\widetilde{\phi}_X(\mathbf{x}_i)=\phi_X(\mathbf{x}_i)-\bar{\phi}_X. \tag{92}$$

El producto interno de dos características centradas cumple

$$(\mathbf{K}_{X,c})_{ij} = \langle \widetilde{\phi}_X(\mathbf{x}_i), \widetilde{\phi}_X(\mathbf{x}_j) \rangle_{\mathcal{H}_X} \tag{93}$$

$$= k_X(\mathbf{x}_i, \mathbf{x}_j) - \frac{1}{N}\sum_{r=1}^{N} k_X(\mathbf{x}_i, \mathbf{x}_r) - \frac{1}{N}\sum_{r=1}^{N} k_X(\mathbf{x}_r, \mathbf{x}_j) + \frac{1}{N^2}\sum_{r,s=1}^{N} k_X(\mathbf{x}_r, \mathbf{x}_s). \tag{94}$$

Esta identidad coincide entrada a entrada con el producto matricial

$$\boxed{\mathbf{K}_{X,c} = \mathbf{H}\mathbf{K}_X\mathbf{H}, \qquad \mathbf{K}_{Y,c} = \mathbf{H}\mathbf{K}_Y\mathbf{H}.} \tag{95}$$

Se multiplica por $\mathbf{H}$ a la izquierda y a la derecha porque se centran las características correspondientes a ambas entradas del producto interno de Gram.

Paso 3. Alineamiento normalizado mediante Frobenius

Para matrices del mismo tamaño se define

$$\langle \mathbf{A}, \mathbf{B} \rangle_F = \sum_{i,j} A_{ij}B_{ij} = \operatorname{tr}(\mathbf{A}^\mathsf{T}\mathbf{B}), \qquad \|\mathbf{A}\|_F^2 = \operatorname{tr}(\mathbf{A}^\mathsf{T}\mathbf{A}). \tag{96}$$

El *alineamiento centrado de kernels* es

$$\rho_{\text{RKHS}} = \frac{\langle \mathbf{K}_{X,c}, \mathbf{K}_{Y,c} \rangle_F}{\|\mathbf{K}_{X,c}\|_F \|\mathbf{K}_{Y,c}\|_F}. \tag{97}$$

No se trata, en general, del coeficiente de Pearson clásico.

Paso 4. Numerador en términos de trazas

Como $\mathbf{K}_{X,c}$ es simétrica, al insertar (95) y usar $\mathbf{H}^2 = \mathbf{H}$,

$$\langle \mathbf{K}_{X,c}, \mathbf{K}_{Y,c} \rangle_F = \operatorname{tr}(\mathbf{K}_{X,c}^\mathsf{T}\mathbf{K}_{Y,c}) \tag{98}$$

$$= \operatorname{tr}(\mathbf{H}\mathbf{K}_X\mathbf{H}\mathbf{H}\mathbf{K}_Y\mathbf{H}) \tag{99}$$

$$= \operatorname{tr}(\mathbf{H}\mathbf{K}_X\mathbf{H}\mathbf{K}_Y\mathbf{H}) \tag{100}$$

$$= \operatorname{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_Y\mathbf{H}^2) \tag{101}$$

$$= \boxed{\operatorname{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_Y\mathbf{H})}. \tag{102}$$

En la penúltima igualdad se aplicó la propiedad cíclica de la traza, que es válida para matrices cuadradas compatibles.

Paso 5. Denominador en términos de trazas

También,

$$\|\mathbf{K}_{X,c}\|_F^2 = \operatorname{tr}(\mathbf{K}_{X,c}^\mathsf{T}\mathbf{K}_{X,c}) \tag{103}$$

$$= \operatorname{tr}(\mathbf{H}\mathbf{K}_X\mathbf{H}\mathbf{H}\mathbf{K}_X\mathbf{H}) \tag{104}$$

$$= \operatorname{tr}(\mathbf{H}\mathbf{K}_X\mathbf{H}\mathbf{K}_X\mathbf{H}) \tag{105}$$

$$= \boxed{\operatorname{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_X\mathbf{H})}. \tag{106}$$

Análogamente,

$$\boxed{\|\mathbf{K}_{Y,c}\|_F^2 = \operatorname{tr}(\mathbf{K}_Y\mathbf{H}\mathbf{K}_Y\mathbf{H}).} \tag{107}$$

Al sustituir las tres identidades en (97) se obtiene exactamente (88). Todos los productos que figuran bajo la traza son de dimensión $N \times N$, por lo que cada traza es escalar.

Paso 6. Caso de kernels lineales y datos escalares

Si $P = Q = 1$ y

$$k_X(x_i, x_j) = x_i x_j, \qquad k_Y(y_i, y_j) = y_i y_j, \tag{108}$$

entonces

$$\boxed{\mathbf{K}_X = \mathbf{x}\mathbf{x}^\mathsf{T}, \qquad \mathbf{K}_Y = \mathbf{y}\mathbf{y}^\mathsf{T}.} \tag{109}$$

Para el numerador, sustituyendo estas matrices,

$$\begin{aligned} \operatorname{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_Y\mathbf{H}) &= \operatorname{tr}(\mathbf{x}\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y}\mathbf{y}^\mathsf{T}\mathbf{H}) && (110)\\ &= (\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y})\operatorname{tr}(\mathbf{x}\mathbf{y}^\mathsf{T}\mathbf{H}) && (111)\\ &= (\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y})(\mathbf{y}^\mathsf{T}\mathbf{H}\mathbf{x}) && (112)\\ &= \boxed{(\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y})^2}. && (113) \end{aligned}$$

Aquí se usó $\operatorname{tr}(\mathbf{a}\mathbf{b}^\mathsf{T}) = \mathbf{b}^\mathsf{T}\mathbf{a}$ y la simetría de $\mathbf{H}$. Para los factores del denominador, el mismo cálculo produce

$$\begin{aligned} \operatorname{tr}(\mathbf{K}_X\mathbf{H}\mathbf{K}_X\mathbf{H}) &= (\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x})^2, && (114)\\ \operatorname{tr}(\mathbf{K}_Y\mathbf{H}\mathbf{K}_Y\mathbf{H}) &= (\mathbf{y}^\mathsf{T}\mathbf{H}\mathbf{y})^2. && (115) \end{aligned}$$

Puesto que $\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x} = \|\mathbf{H}\mathbf{x}\|_2^2 > 0$ y $\mathbf{y}^\mathsf{T}\mathbf{H}\mathbf{y} = \|\mathbf{H}\mathbf{y}\|_2^2 > 0$ bajo la hipótesis de denominadores no nulos,

$$\begin{aligned} \rho_{\mathrm{RKHS}} &= \frac{(\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y})^2}{\sqrt{(\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x})^2(\mathbf{y}^\mathsf{T}\mathbf{H}\mathbf{y})^2}} && (116)\\ &= \frac{(\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y})^2}{(\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x})(\mathbf{y}^\mathsf{T}\mathbf{H}\mathbf{y})} && (117)\\ &= \left[\frac{\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{y}}{\sqrt{(\mathbf{x}^\mathsf{T}\mathbf{H}\mathbf{x})(\mathbf{y}^\mathsf{T}\mathbf{H}\mathbf{y})}}\right]^2. && (118) \end{aligned}$$

Comparando con (69), concluimos

$$\boxed{\rho_{\mathrm{RKHS}} = \widehat{\rho}_{XY}^{\,2}.} \tag{119}$$

Paso 7. Interpretación de la pérdida del signo

El coeficiente $\widehat{\rho}_{XY} \in [-1, 1]$ conserva la dirección de la asociación lineal; sin embargo, su cuadrado es no negativo:

$$(-0.8)^2 = (+0.8)^2 = 0.64. \tag{120}$$

El alineamiento centrado de kernels lineales escalares no distingue una relación creciente de otra decreciente de igual magnitud. De forma equivalente, al sustituir $\mathbf{x}$ por $-\mathbf{x}$,

$$(-\mathbf{x})(-\mathbf{x})^\mathsf{T} = \mathbf{x}\mathbf{x}^\mathsf{T} = \mathbf{K}_X, \tag{121}$$

por lo que la matriz de Gram y su alineamiento permanecen invariantes, aunque la correlación de Pearson cambia de signo: $\widehat{\rho}_{(-X)Y} = -\widehat{\rho}_{XY}$.

Conclusión de la sección 3

Pearson normaliza el producto interno entre vectores de observaciones centrados; el alineamiento en RKHS normaliza el producto interno de Frobenius entre matrices de Gram centradas. Para kernels lineales escalares, las matrices de Gram son productos exteriores de vectores y el alineamiento se reduce al cuadrado de la correlación de Pearson. Por eso cuantifica la intensidad de la asociación lineal sin conservar su signo.